

# XAI aplicada a la discriminación de ocurrencia de inundación por tsunami mediante 1D CNN

1<sup>st</sup> Matías Sifón  
Dirección de Postgrados  
UTFSM  
Valparaíso, Chile  
msifon@usm.cl

2<sup>nd</sup> Ignacio Muñoz  
Departamento de Informática  
UTFSM  
Valparaíso, Chile  
ignacio.munozu@usm.cl

3<sup>rd</sup> Tomás Mercado  
Departamento de Electronica  
UTFSM  
Valparaíso, Chile  
tomas.mercado@usm.cl

**Index Terms**—XAI, tsunami, inundación, redes neuronales

## I. CONTEXTO DE APLICACIÓN

Los tsunamis son fenómenos poco frecuentes que, cuando ocurren, pueden causar desastres si no son gestionados apropiadamente, existiendo registros de alrededor de 250.000 muertes por tsunami entre 1990 y 2023 [14]. Es por ello que los Centros Nacionales de Alerta de Tsunami (CNAT) del mundo han adoptado diversas estrategias que les permitan predecir ciertas características de las ondas de tsunami y el potencial impacto en sus respectivos países antes que arribe a las costas, siendo el principal desafío el poco tiempo disponible para reaccionar. Por ejemplo, en caso de terremotos frente a las costas de Chile, el tsunami podría llegar a sus costas tan solo algunos minutos después del origen del terremoto [1]–[4].

El caso ideal sería tener toda la información para efectuar modelaciones directas del tsunami en curso y obtener los resultados antes del arribo considerando las 3 etapas (generación, propagación e inundación), sin embargo, el poco tiempo disponible para actuar ha llevado a que los CNAT se enfoquen en las dos primeras debido al gran costo computacional de modelar de manera directa la inundación [4], obteniendo pronósticos de la máxima altura de tsunami (o amplitud en algunos casos) en costa, lo que se transforma en niveles de amenaza que son utilizados por las oficinas de gestión de riesgo de cada país para decretar, o no, evacuaciones del borde costero [3].

Es así que tanto centros nacionales, como el Sistema Nacional de Alarma de Maremotos de Chile (SNAM), e internacionales, como el Centro de Alerta de Tsunamis del Pacífico (PTWC) dependiente de la Oficina Nacional de Administración Oceánica y Atmosférica (NOAA) de Estados Unidos, poseen metodologías que les permiten pronosticar amplitudes o alturas de tsunami en costa a partir de datos básicos de la fuente sísmica y, en algunos casos, incorporar datos de sensores de tsunami en el océano profundo [5]–[7]. Para los CNAT el escenario es más complejo que para los centros internacionales ya que, el caso más extremo ocurre cuando la fuente generadora del tsunami está en cercanías de la costa del país, no alcanzando a obtener mediciones en el océano profundo antes del arribo del tsunami. Ese corto

tiempo influye también en la metodología seleccionada para pronosticar las características del tsunami, debiendo tener presente el tiempo de cómputo de la estrategia seleccionada y las incertidumbres en la información disponible para efectuar las modelaciones. Es por ello que, países como Japón, Australia, Indonesia y Chile, han adoptado estrategias a partir de escenarios pre-modelados de sismo y sus respectivos tsunamis almacenados en una base de datos que, es consultada al ocurrir un terremoto [3], [8]–[10]. Luego, debido a que son escenarios hipotéticos, no contienen las heterogeneidades de la fuente, usando modelos de terremotos simplistas que pueden llevar a una subestimación del *runup* [11]–[13], parámetro que define la máxima altura en terreno que alcanza el tsunami y, por lo tanto, relacionado con la inundación que genera éste. Por ello, estas bases de datos contienen la información sobre la modelación directa de las dos primeras etapas del tsunami (generación y propagación).

La complejidad de hacerse cargo de la inundación de un tsunami en un contexto de alerta temprana, considerando la modelación directa, radica en dos factores principalmente: la dependencia del *runup* de las heterogeneidades de la fuente generadora y el costo computacional de la resolución de modelos no lineales. Luego, las evaluaciones de amenaza de tsunami normalmente omiten la inundación y basan sus estimaciones de impacto en alturas en la costa a partir de las estrategias mencionadas como aproximación al nivel de peligro, para determinar si las comunidades costeras deben evacuar hacia zonas en altura o no.

Núñez et al [4] ahondan de manera más profunda en las complejidades de incorporar la inundación, proponiendo un modelo de redes neuronales convolucionales de 1 dimensión para discriminar la ocurrencia de inundación en el contexto de alerta temprana de tsunamis. El modelo utiliza series temporales medidas o simuladas aguas afuera, para predecir series temporales de inundación en una determinada ubicación costa adentro y una posterior clasificación binaria del escenario: inunda o no inunda.

En el artículo, se presenta la implementación de la metodología para cuatro localidades de Chile, Viña del Mar, Valparaíso, Coquimbo y La Serena. Para entrenar el modelo se usaron 6776 escenarios, con un 70% de ellos para entrenamiento, 15% para test y otro 15% para validación.

Para determinar la combinación de hiperparámetros que produce el mejor desempeño, se utilizó el Error Cuadrático Medio (MSE por sus siglas en inglés) y mínimos cuadrados normalizados. Durante la evaluación de desempeño el modelo tuvo buen comportamiento, fallando en la predicción binaria de inundación en poco más de 50 escenarios de un total de 1017 usados para la etapa de test, existiendo casos de falsos positivos y falsos negativos es decir, casos en que el modelo indicó inundación pero el tsunami no inundó, así como casos en que el modelo indicó no inundación y el tsunami si inundó, siendo el último el más grave para alerta temprana, aunque ambos casos son de interés y preocupación para un CNAT. Adicionalmente, se llevaron a cabo pruebas con los eventos reales ocurridos en 2010 y 2015, mostrando un comportamiento similar.

El modelo expuesto usa arquitecturas compactas de redes neuronales convolucionales de 1 dimensión (CNN-1D), determinando parámetros e hiperparámetros, con el objetivo principal de estimar la capacidad predictiva de inundaciones por tsunami. La metodología se implementó en Python 3.6, usando la API Keras dentro de TensorFlow, con un optimizador ADAM con tasa de aprendizaje 0,001, en un ordenador portátil de uso comercial. En mayor detalle, como se muestra en la figura 1, el modelo presentado tiene una arquitectura que considera como entrada una serie temporal (1D), luego un bloque de convolución con tres capas convolucionales 1D aplicadas de forma consecutiva, para luego incorporar una capa de normalización (*Batch Normalization*). Posteriormente la salida normalizada se "aplana" a un vector. Las capas finales corresponden a dos capas densas (*fully connected*) conectadas de manera secuencial para la salida. Después de cada capa densa se aplica una capa *Dropout* para reducir el sobre ajuste. Antes de la salida final, se aplica una activación del tipo ReLu, ya que esto permite solo valores no negativos, lo que tiene sentido con la física del problema, ya que tanto tiempos como alturas de inundación son valores positivos o nulos.

En el contexto de alerta temprana de tsunamis, es de gran interés y potencial utilidad analizar la posibilidad de dar explicabilidad a los resultados obtenidos por el modelo, para lo que se contactó a los autores del trabajo presentado en [4], quienes accedieron a brindar acceso, tanto a los datos como al modelo, a los autores del presente informe, con el objetivo de implementar alguna estrategia de Inteligencia Artificial Explicable (XAI) y dar un mayor valor a los resultados. Los datos corresponden principalmente a series de tiempo de tsunami, los que ya fueron procesados.

## II. PRESENTACIÓN DE PROBLEMA

El problema que se presenta, radica en la falta de información para que el usuario final de un modelo como el propuesto confíe en los resultados que entrega, ya que un CNAT no puede implementar un sistema que tenga falsos positivos y falsos negativos sin tener mayor información al respecto.




Fig. 1. Esquema de la arquitectura de la red presentada por Núñez et al (2022). El panel superior muestra todos los pasos usando la nomenclatura especificada en la literatura. El panel inferior representa la extracción de características realizada por una capa convolucional. Figura extraída de [4].

En ese sentido, la hipótesis planteada es que al aplicar una metodología de XAI a este modelo de Machine Learning, se puede entregar mayor confiabilidad al tener explicaciones mas interpretables de los resultados generados, para que un CNAT pueda usarlo en la toma de decisiones que generen acciones como la evacuación (o no) del borde costero ante un evento de tsunami.

La motivación del presente trabajo recae en la necesidad de los países de mejorar los sistemas de alerta temprana de tsunamis. Hasta nuestro conocimiento, ningún centro de alerta de tsunamis en el mundo incorpora la inundación en sus procesos de decisión, siendo que es la etapa del tsunami que causa mayores daños en las comunidades. La IA ha permitido avanzar en la resolución de problemas complejos como este, sin embargo, es necesario tener en cuenta que el modelo con la arquitectura presentada en la figura 1 tiene el comportamiento de una caja negra y, mientras no tenga un desempeño probado y asegurado de 100% de precisión (lo que pareciera ser imposible con el estado del conocimiento actual), ningún tomador de decisiones se arriesgará a implementarlo, a menos que cuente con una herramienta que le permita decidir si utilizar la información brindada o no. En ese sentido, aplicar técnicas de XAI, que den una explicación de los resultados, se posiciona como una solución a esa situación, siendo realista pensar que un centro de alerta de tsunamis podría implementarlo de manera operacional, lo que contribuiría a una mejor gestión de emergencias por tsunami y a avanzar en el estado del arte de los centros de alerta de tsunamis.

Como objetivo general se pretende evaluar si la aplicación de técnicas de XAI a este modelo de redes neuronales para predecir si un determinado tsunami genera o no inundación en algunas localidades de Chile mejora la confiabilidad y

la aceptabilidad operativa de sus predicciones por parte del SNAM, de modo que puedan emplearse en decisiones críticas, llevando por ejemplo, a procesos de evacuaciones del borde costero.

Como objetivos específicos se plantea:

- 1) Replicar el modelo presentado por [4], con la arquitectura CNN 1D compacta para la predicción de inundaciones, definiendo y ajustando los parámetros e hiperparámetros, para una localidad por determinar.
- 2) Aplicar técnicas de XAI para explicar las predicciones del modelo.
- 3) Evaluar el impacto de las explicaciones en la percepción de confiabilidad por expertos del SNAM mediante una presentación a potenciales usuarios.
- 4) Medir el rendimiento operativo usando métricas predictivas (precisión, recall, F1, tasa de falsos positivos/negativos), latencia y requisitos computacionales para un entorno operativo.

Para cumplir con lo anterior y poder llevar a cabo el proyecto, es fundamental la comunicación con los autores del artículo en [4], quienes demostraron plena disposición a apoyar el desarrollo de este trabajo, lo que hace que sea factible desarrollar el estudio.

### III. PRESENTACIÓN DE LOS MÉTODOS

Para el desarrollo del proyecto se deberá replicar el modelo propuesto por [4], cuya arquitectura se muestra en la figura 1. Así, el modelo de Machine Learning (ML) que se implementará, será un modelo de redes neuronales convolucionales unidimensional, con la estructura de capas indicadas.

Respecto de los métodos de XAI, es importante tener en cuenta que el modelo de ML que se replicará posee dos salidas: la primera salida corresponde a una serie de tiempo de altura de tsunami costa adentro, para posteriormente aplicar una función de activación ReLu, que permite obtener una segunda salida con resultado binario, cuyas categorías son "inunda" y "no inunda".

Considerando lo anterior, se pretende implementar un método de XAI contrafactual a la última salida del modelo, que permita cuantificar las variaciones que se requieren para que se produzca un cambio en la clasificación binaria. Dicho de otra forma, qué tanto tiene que cambiar el tsunami para que deje de generar inundación o comience a inundar, según corresponda. El método en particular aun no ha sido definido por el equipo de trabajo, dado que se requiere más estudio y conocimiento en detalle del modelo de ML para definirlo.

Asimismo, dado que existe una salida previa a la binaria, será interesante explorar si es pertinente implementar alguna herramienta de XAI a las series de tiempo que se obtienen luego de la capa *Dropout*, lo que será materia de estudio durante el desarrollo del proyecto.

### REFERENCES

[1] Fritz, H. M., Petroff, C. M., Catalán, P. A., Cienfuegos, R., Winckler, P., Kalligeris, N., Weiss, R., Barrientos, S. E., Meneses, G., Valderas-Bermejo, C., Ebeling, C., Papadopoulos, A., Contreras, M., Almar, R.,

Dominguez, J. C., & Synolakis, C. E. (2011). Field Survey of the 27 February 2010 Chile Tsunami. *Pure and Applied Geophysics*, 168(11), 1989–2010. <https://doi.org/10.1007/s00024-011-0283-5>

[2] Aránguiz, R., González, G., González, J. et al. The 16 September 2015 Chile Tsunami from the Post-Tsunami Survey and Numerical Modeling Perspectives. *Pure Appl. Geophys.* 173, 333–348 (2016). <https://doi.org/10.1007/s00024-015-1225-4>

[3] Catalan, P. A., Gubler, A., Cañas, J., Zuñiga, C., Zelaya, C., Pizarro, L., Valdes, C., Mena, R., Toledo, E., & Cienfuegos, R. (2020). Design and operational implementation of the integrated tsunami forecast and warning system in Chile (SIPAT). *Coastal Engineering Journal*, 62(3), 373–388. <https://doi.org/10.1080/21664250.2020.1727402>

[4] Núñez, J., Catalán, P. A., Valle, C., Zamora, N., & Valderrama, A. (2022). Discriminating the occurrence of inundation in tsunami early warning with one-dimensional convolutional neural networks. *Scientific Reports*, 12(1). <https://doi.org/10.1038/s41598-022-13788-9>

[5] Bernard, E., Meinig, C., Titov, V. V., & Wei, Y. 50 years of PMEL tsunami research and development. *Oceanography*, 36(2–3), 175–185. 2023.

[6] Mori, N., Satake, K., Cox, D., Goda, K., Catalan, P. A., Ho, T.-C., Imamura, F., Tomiczek, T., Lynett, P., Miyashita, T., Muhari, A., Titov, V., & Wilson, R. Giant tsunamis monitoring, early warning and hazard assessment. *Nature Reviews Earth & Environment*, 3(8), 557–572. 2022.

[7] Titov, V. V., Meinig, C., Stalin, S., Wei, Y., Moore, C., & Bernard, E.. Technology transfer of PMEL tsunami research protects populations and expands the new blue economy. *Oceanography*, 36 (2–3), 186–195, 2023.

[8] Pradana, D. H. F., Wiguna, E. A., Rusdiatomo, A., Saputri, A. N., Wibowo, M., & Hendriyono, W. Development of real-time tsunami early warning system dashboard based on Tunami-F1 and machine learning in Sunda Arc, Indonesia. In 2022 IEEE Ocean Engineering Technology and Innovation Conference: Ocean Observation, Technology and Innovation in Support of Ocean Decade of Science (OETIC) (pp. 1–6). IEEE, 2022.

[9] Greenslade, D.J.M., Uslu, B., Allen, S.C.R. et al. Evaluation of Australian Tsunami Warning Thresholds Using Inundation Modelling. *Pure Appl. Geophys.* 177, 1425–1436 (2020). <https://doi.org/10.1007/s00024-019-02377-z>

[10] Osamu Kamigaichi, Makoto Saito, Keiji Doi, Toshiyuki Matsumori, Shin'ya Tsukada, Kiyoshi Takeda, Toshihiro Shimoyama, Kouji Nakamura, Masashi Kiyomoto, Yukihiko Watanabe; Earthquake Early Warning in Japan: Warning the General Public and Future Prospects. *Seismological Research Letters* 2009;; 80 (5): 717–726. doi: <https://doi.org/10.1785/gssrl.80.5.717>

[11] Geist, E. L. Complex earthquake rupture and local tsunamis. *Journal of Geophysical Research: Solid Earth*, 107(B5), ESE-2, 2002.

[12] Ruiz, J., Fuentes, M., Riquelme, S., Campos, J., & Cisternas, A. Numerical simulation of tsunami runup in northern Chile based on non uniform k2 slip distributions. *Natural Hazards* 79, 1177–1198, 2015.

[13] Fuentes, M., Arriola, S., Riquelme, S., & Delouis, B. Speeding up tsunami forecasting to boost tsunami warning in Chile. *Natural Hazards and Earth System Sciences*, 19(6), 1297–1304, 2019.

[14] National Centers for Environmental Information. (2023, March). Tsunami Sources B.C. 1610 to A.D. 2023. U.S. National Oceanic and Atmospheric Administration. <https://www.ncei.noaa.gov/>